Atualidades e Inteligência Artificial

Repositório Central de Concursos de TIC · UFRRJ & Transpetro 2026

Caderno Consolidado de Atualidades e Inteligência Artificial — teoria completa, mnemônicos e pegadinhas de prova.

Gerado automaticamente em 10/11/2026.

Sumário

• Atualidades e IA T01 — Tópicos Relevantes e Atuais
• Atualidades e IA T02.1 — Conceitos Fundamentais de Inteligência Artificial
• Atualidades e IA T02.2 — Aprendizado de Máquina (Machine Learning)
• Atualidades e IA T02.3 — Modelos Generativos e Modelos de Linguagem (LLMs)
• Atualidades e IA T02.4 — Ética, Governança e Privacidade em IA

Atualidades e IA T01 — Tópicos Relevantes e Atuais

■■ Visão Geral do Tópico

Cobre os grandes temas contemporâneos cobrados pela FGV no Módulo I (Conhecimentos Gerais): geopolítica global (BRICS+, G20), diplomacia climática e meio ambiente (COP30 em Belém, Acordo de Paris, transição energética), Objetivos de Desenvolvimento Sustentável (ODS 11 e o ODS 18 brasileiro), economia e comércio exterior (relações Brasil–EUA, tarifas, commodities, mineração), recursos hídricos e controle de enchentes, segurança pública (letalidade policial e perfil sociodemográfico da violência) e políticas públicas de Ciência, Tecnologia & Inovação (ações afirmativas e igualdade de gênero).

Do que se trata?

A prova de Atualidades da FGV não cobra fofocas de jornal ou palpites soltos de redes sociais. Ela exige **leitura institucional, sociológica e geopolítica madura** dos acontecimentos que moldam as políticas públicas e o comércio exterior do Brasil.

```
flowchart TD
A["Atualidades FGV"] --> B["Geopolítica & Diplomacia"]
A --> C["Meio Ambiente & Clima"]
A --> D["Economia & Comércio"]
A --> E["Sociedade & Cidadania"]

B --> B1["BRICS+ (Expansão de Johanesburgo)"]
B --> B2["G20 (19 Países + UE + União Africana)"]

C --> C1["COP30 em Belém (UNFCCC / Acordo de Paris)"]
```

```
C --> C2["ODS 11 (Cidades) e ODS 18 (Igualdade Racial)"]
C --> C3["Hidrologia: Estrutural vs Não-Estrutural"]

D --> D1["Balança Comercial (Commodities: Soja, Petróleo, Ferro)"]
D --> D2["Tarifas dos EUA (Protecionismo e Exceções)"]
D --> D3["Produção Mineral (MG e PA na liderança)"]

E --> E1["Segurança Pública (Violência Letal e Raça)"]
E --> E2["CT&I (Equidade de Gênero e Ações Afirmativas)"]
E --> E3["Cultura & Identidade (Ailton Krenak na ABL)"]
```

Os grandes eixos temáticos dividem-se em:

■ **Geopolítica e Governança Global:**

• **Expansão do BRICS (BRICS+):** Aprovada na Cúpula de Johanesburgo II (2023), oficializada em janeiro de 2024. Ingressaram Egito, Etiópia, Irã e Emirados Árabes Unidos (a Arábia Saudita participou de reuniões e a Argentina de Javier Milei declinou formalmente).

• **Composição do G20:** Fórmula canônica **19 + 2** — 19 países soberanos + União Europeia + União Africana (admitida como membro permanente em 2023 sob presidência indiana). O Brasil presidiu o G20 em 2024 com foco em combate à fome, transição energética justa e reforma das instituições de governança global.

■ **Clima, Meio Ambiente e Desenvolvimento Sustentável:**

• **COP30 (2025/2026 em Belém do Pará):** A Conferência das Partes da UNFCCC no coração da Amazônia brasileira. Marcos negociadores: financiamento climático, transição para longe de combustíveis fósseis (*UAE Consensus*), metas nacionais de redução de emissões (NDCs) e adaptação climática.

• **O Acordo de Paris:** Regime multilateral voluntário, baseado em metas nacionais autorreguladas (NDCs) e transparência mútua, **sem sanções financeiras, comerciais ou militares punitivas** para quem não cumprir metas.

• **ODS 11 vs ODS 18:** O ODS 11 cuida de *Cidades e Comunidades Sustentáveis* (habitação digna, saneamento, transporte coletivo e resiliência a desastres). O **ODS 18 é uma criação voluntária exclusiva do Brasil**, lançada na ONU pelo governo federal em 2023, dedicada especificamente à *Igualdade Étnico-Racial*.

• **Controle de Inundações e Recursos Hídricos:** Distinção entre **Medidas Estruturais** (obras físicas de engenharia pesada: diques, canalizações, piscinões, desassoreamento) e **Medidas Não-Estruturais** (gestão de bacia, zoneamento do solo, sistemas de alerta meteorológico, planos de evacuação e preservação de matas ciliares).

■ **Economia, Comércio Exterior e Recursos:**

• **Balança Comercial Brasileira:** O superávit histórico do Brasil é sustentado pela exportação de *commodities* brutas (tríade: soja, petróleo cru e minério de ferro).

• **Parceiros Comerciais:** China é o maior parceiro individual do Brasil (maior destino de exportações e origem de importações), seguida por União Europeia e Estados Unidos.

• **Tarifas e Protecionismo Norte-Americano:** A dinâmica de elevação de tarifas alfandegárias unilaterais pelos EUA (como sobre aço, alumínio e bens manufaturados) impõe desafios à indústria nacional, operando por listas de exceção pontuais negociadas diplomaticamente.

• **Produção Mineral Brasileira:** Concentrada fortemente em dois estados líderes absolutos: **Minas Gerais** e **Pará** (que juntos respondem por mais de 80% do valor da produção mineral do país, sobretudo ferro e bauxita).

■ **Sociedade, Cidadania e Políticas Públicas:**

• **Segurança Pública e Violência Letal:** Dados do Fórum Brasileiro de Segurança Pública (FBSP) e Atlas da Violência mostram que a letalidade violenta atinge de forma desproporcional jovens homens negros das periferias urbanas (com taxas críticas no Norte e Nordeste, como na Bahia).

• **Políticas de CT&I e Equidade de Gênero:** Editais recentes do MCTI, CNPq e Finep estruturam ações afirmativas obrigatórias para promover a liderança feminina na pesquisa acadêmica e nas ciências exatas.

• **Cultura e Literatura Indígena:** Eleição histórica do filósofo e escritor indígena **Ailton Krenak** para a Academia Brasileira de Letras (ABL) em 2023 (Cadeira nº 5), consolidando o reconhecimento dos saberes e cosmovisões dos povos originários na cultura institucional do país.

Por que cai em prova?

A FGV usa as questões de Atualidades para testar se o futuro servidor público possui:

• **Senso de realidade geopolítica e diplomática:** Saber quem integra quais blocos, quais tratados estão em vigor e como o Brasil se posiciona internacionalmente.

• **Rigor factual e terminológico:** Evitar achismos. A banca troca nomes de tratados, inverte membros plenos com convidados, e inventa penalidades que os acordos não preveem.

• **Compreensão das desigualdades estruturais:** A banca cobra leitura técnica dos indicadores sociais (Anuário de Segurança Pública, IBGE, Ipea, Secex/MDIC).

Como as partes se conectam?

• **Com Governança de TIC e Dataprev:** A Dataprev é a estatal responsável pelos dados sociais do Brasil (Bolsa Família, Previdência, Cadastro Único). Conhecer o perfil sociodemográfico da vulnerabilidade e as metas dos ODS dialoga diretamente com as políticas públicas digitais operadas pela empresa.

• **Com Ética e Legislação:** As metas de transparência, combate ao racismo (ODS 18) e equidade de gênero refletem as diretrizes constitucionais e as leis de acesso e proteção de dados.

• **Com T02 (Inteligência Artificial):** A diplomacia contemporânea discute tratados internacionais de governança algorítmica (como a Convenção de Vilnius) no mesmo fórum em que negocia transição climática e comércio global.

Pegadinhas clássicas da FGV

■■ PEGADINHA

A Composição Oficial do G20 (O mito dos "20 países"):

A banca costuma listar "20 países soberanos" ou afirmar que o G20 é composto unicamente por chefes de Estado nacionais.

A realidade factual: O G20 é formado por **19 países soberanos + 2 organizações regionais** (a União Europeia e a recém-integrada União Africana). Jamais marque que são "20 países".

■■ PEGADINHA

Natureza Punitiva do Acordo de Paris:

A FGV adora formular alternativas afirmando que o Acordo de Paris "estabelece multas pesadas e sanções comerciais automáticas aos países que descumprirem suas metas de redução de emissões".

A verdade jurídica: O Acordo de Paris baseia-se em compromissos voluntários (*Contribuições Nacionalmente Determinadas — NDCs*) e em um mecanismo de facilitação e transparência (*name and*

shame), **sem nenhuma previsão de sanções econômicas ou punições jurídicas coercitivas**.

■■ PEGADINHA

O 18º ODS — Exclusividade Brasileira:

A banca afirma que a Agenda 2030 da ONU aprovou um novo ODS mundial em sua assembleia geral para todos os 193 países membros.

Atenção: Os ODS originais da ONU continuam sendo **17**. O ODS 18 (*Igualdade Étnico-Racial*) é uma iniciativa **voluntária e nacional do Brasil**, adotada internamente para orientar o Plano Plurianual (PPA) e políticas afirmativas do governo brasileiro.

■ ALERTA

Controle de Inundações: Estrutural × Não-Estrutural:

Se a medida exige concreto, trator e canteiro de obras (construir piscinões, canalizar córregos, altear diques, desassorear rios), ela é **ESTRUTURAL**.

Se a medida envolve leis, mapas, avisos e planejamento (zoneamento urbano, sistema de sirenes, proibição de construção em encostas, educação comunitária), ela é **NÃO-ESTRUTURAL**. A banca adora classificar o zoneamento do solo como "medida estrutural de contenção".

■ DICA

Balança Comercial — A Tríade das Commodities:

Em qualquer questão sobre a pauta exportadora brasileira recente, lembre-se: o superávit brasileiro é amplamente dependente da trinca **Soja em grãos**, **Petróleo bruto** e **Minério de ferro**. Bens manufaturados de alta complexidade representam a menor fatia das exportações e a maior das importações.

O que separa quem acerta de quem erra?

Critério	Quem Erra	Quem Acerta
	Membros do BRICS	Acha que Argentina entrou no bloco porque foi aprovada em 2023.
	COP30	Acha que a COP é um evento punitivo com poder de polícia internacional.
	Segurança Pública	Trata a violência como fenômeno homogêneo ou aleatório em todo o país.
	Produção Mineral	Marca estados do Sudeste genérico ou Sul.

Onde eu erraria e por quê?

O erro mais comum nesta matéria é tentar responder por **intuição política ou sentimento pessoal**. A FGV redige distratores muito bem articulados que apelam para o que "deveria ser" no senso comum. A única blindagem é apoiar-se em **documentos institucionais**: relatórios do Secex, declarações finais de cúpulas

internacionais, redação das NDCs e dados oficiais do IBGE/Ipea.

Como memorizar sem decorar?

- **G20:** Fórmula `19 + 2` (19 países + União Europeia + União Africana).
- **BRICS Expansão (2024):** Lembrar da sigla mnemônica **EEII**: **E**gito, **E**tiópia, **I**rã e **I**rmãos dos Emirados Árabes.
- **Prevenção de Inundações:** *"Estrutural mexe na terra e no rio; Não-estrutural mexe na regra e no aviso."*

O que revisar e quando?

- **Revisão Relâmpago (30 dias antes):**
  - Lista exata dos membros do G20 e BRICS+.
  - Cidade e pautas centrais da COP30 (Belém/Amazônia).
  - ODS 11 (Cidades) e ODS 18 (Igualdade Racial brasileira).
- **Revisão Fina (véspera):**
  - Tríade das commodities exportadas pelo Brasil (soja, petróleo, minério de ferro).
  - Diferença entre medidas estruturais e não-estruturais de drenagem.

Lição para outras matérias

A precisão terminológica é universal na FGV: assim como uma vírgula deslocada em Português altera o sentido do período, a troca de uma palavra ("voluntário" por "punitivo", ou "19 países" por "20 países") derruba a alternativa inteira. Ler devagar cada palavra do enunciado é metade da nota.

Atualidades e IA T02.1 — Conceitos Fundamentais de Inteligência Artificial

■■ Visão Geral do Tópico

Abrange as bases conceituais da Inteligência Artificial em provas de TIC: origens históricas (Dartmouth 1956, AI Winters e o salto do Deep Learning), taxonomia dos níveis de capacidade (ANI vs. AGI vs. ASI), a arquitetura de agentes inteligentes de Russell & Norvig e o moderno paradigma da IA Agêntica (*Agentic AI*).

Do que se trata?

A Inteligência Artificial (IA) não começou com o ChatGPT em 2022. Trata-se de uma disciplina científica formal com quase sete décadas de história, caracterizada por ciclos sucessivos de entusiasmo vertiginoso, promessas exageradas, quedas abruptas de financiamento e renascimentos espetaculares.

```
flowchart TD
A["História da IA"] --> B["1956: Conferência de Dartmouth"]
B --> C["1º Inverno da IA (Anos 70)"]
C --> D["Sistemas Especialistas (Anos 80)"]
D --> E["2º Inverno da IA (Final dos 80)"]
E --> F["Renascimento Moderno (2012+)"]
F --> F1["Big Data + GPUs + Redes Profundas"]

G["Níveis de Capacidade"] --> H["ANI: Estreita / Aplicada (Realidade Hoje)"]
G --> I["AGI: Geral / Humana (Horizonte Teórico)"]
G --> J["ASI: Superinteligência (Hipotética)"]
```

1.1 A Linha do Tempo e os "Invernos da IA" (*AI Winters*)

• **1956 — Conferência de Dartmouth:** John McCarthy, Marvin Minsky, Claude Shannon e Nathaniel Rochester cunham oficialmente o termo *"Inteligência Artificial"*, estabelecendo o pressuposto de que qualquer aspecto da inteligência e do aprendizado pode ser formulado de modo que uma máquina consiga simulá-lo.

• **O 1º Inverno da IA (década de 1970):** Ocorre após o choque de realidade sobre as limitações dos primeiros computadores e a prova matemática de Marvin Minsky e Seymour Papert sobre a incapacidade dos *Perceptrons* de camada única em resolver problemas não-lineares (como o OU-Exclusivo / XOR). O *Relatório Lighthill* no Reino Unido e o corte de verbas da DARPA nos EUA congelaram as pesquisas por quase uma década.

• **A Era dos Sistemas Especialistas (início dos anos 1980):** A IA renasce com base em regras simbólicas rígidas (*if-then*) programadas manualmente por engenheiros de conhecimento (como o sistema MYCIN).

• **O 2º Inverno da IA (final dos anos 1980):** Os sistemas especialistas mostraram-se caros demais para manter, incapazes de lidar com incertezas e com quebras catastróficas diante de situações ligeiramente fora da regra. O colapso do mercado de computadores especializados em linguagem Lisp desencadeou o segundo corte massivo de investimentos.

• **O Renascimento Moderno (a partir de 2012):** A vitória histórica da rede neural convolucional **AlexNet** na competição *ImageNet* provou que a combinação de três fatores transformou a IA: **Big Data** (dados massivos para treino), **GPUs** (poder computacional paralelo de placas gráficas) e **Redes Neurais Profundas** (*Deep Learning*).

1.2 Os Três Níveis de Capacidade da IA

Nível	Nomenclatura	Definição e Escopo	Status Tecnológico
	ANI	*Artificial Narrow Intelligence* (IA Estreita ou Fraca)	Sistema especializado em executar com alta competência **uma única tarefa ou um domínio estrito**. É inflexível fora do seu escopo de treinamento.

	AGI	*Artificial General Intelligence* (IA Geral ou Forte)	Sistema com capacidade cognitiva humana ampla: aprende qualquer tarefa intelectual, transfere conhecimento entre domínios distintos, raciocina sobre conceitos inéditos e possui bom senso adaptativo.
	ASI	*Artificial Superintelligence* (Superinteligência)	Sistema hipotético cuja capacidade intelectual supera em ordens de magnitude a mente humana mais brilhante em todas as áreas (criatividade, ciências, filosofia, relações sociais).

1.2.1 A Filosofia da IA: Alan Turing × John Searle (O Quarto Chinês)

No debate epistemológico sobre a mente e as máquinas:

- **Alan Turing (Visão Comportamental / Teste de Turing):** Defendeu que, se uma máquina consegue se comunicar de forma indistinguível de um ser humano, devemos considerá-la inteligente. O foco reside na **saída externa e no comportamento**.
- **John Searle (Visão Intencional / O Quarto Chinês):** Em 1980, Searle formulou o célebre experimento mental do *Quarto Chinês* para provar que a **simulação de inteligência não é inteligência real**. Um homem trancado em um quarto manipulando símbolos em mandarim com base em um livro de regras sintáticas (*se vir o símbolo X, responda Y*) parecerá fluente para quem está do lado de fora, mas **ele não compreende uma única palavra em mandarim**.
    - **Sintaxe vs. Semântica:** A máquina manipula símbolos e padrões estatísticos (**sintaxe**), mas não possui acesso ao significado nem compreensão do mundo (**semântica**).
    - **IA Fraca apenas simula a mente**; a **IA Forte teria mente genuína, consciência e intencionalidade**.

1.2.2 Taxonomia por Escopo e Criação: Discriminativa × Generativa

- **IA Discriminativa (Preditiva):** Aprende os limites de decisão $P(y|x)$ entre classes para rotular ou prever valores (ex.: classificar e-mail como spam, detecção de fraude).
- **IA Generativa (Sintética):** Modela a distribuição de probabilidade conjunta $P(x, y)$ ou $P(x)$ para **gerar novas instâncias de dados** (textos, imagens, áudios) estatisticamente semelhantes à base de treino, mas inéditas.

■■ Inversão Conceitual e o Fetiche do Hardware

Inversão Espelhada: A banca tenta confundir o candidato rápido invertendo as atribuições: diz que a *IA forte* é restrita a domínios técnicos e que a *IA fraca* possui autoconsciência. Risque na hora!

O Salto Ontológico não é Hardware: Assertivas afirmando que basta "adicionar mais GPUs, memória ou velocidade de processamento" para que uma IA fraca desenvolva consciência são falsas. A transição teórica entre executar tarefas especializadas e manifestar mente consciente exige novos paradigmas arquitetônicos e conceituais, não apenas poder bruto.

■ Dica da Banca — Correspondência de Taxonomia de IA

Em questões de correlação da FGV:

Fixe a **IA Generativa** pela palavra-chave *gerar novos conteúdos/síntese*;

Fixe a **IA Fraca** por *tarefa única/especializada sem consciência*;

Fixe a **IA Forte** por *capacidade intelectual ampla/geral comparável à mente humana*.

Essa ancoragem tripla elimina a maioria dos distratores imediatamente.

1.3 Agentes Inteligentes e a Arquitetura da IA Agêntica

Na formulação clássica de **Stuart Russell e Peter Norvig** (*Inteligência Artificial: Uma Abordagem Moderna*), um **agente** é qualquer entidade que:

- **Percebe** seu ambiente por meio de **sensores**;
- **Processa** as informações orientado a objetivos e utilidade;
- **Age** sobre o ambiente por meio de **atuadores**.

```
flowchart LR
Ambiente["Ambiente"] -->|Sensores| Agente["Agente Inteligente"]
Agente -->|Decisão / Meta| Agente
Agente -->|Atuadores| Ambiente
```

A Escada dos Agentes (Russell & Norvig):

- **Agentes Reativos Simples:** Agem unicamente com base na percepção imediata presente, através de regras *condição-ação* ("se acender luz vermelha, pare"). Não guardam memória nem antecipam consequências.
- **Agentes Reativos Baseados em Modelos:** Mantêm um estado interno para rastrear aspectos do ambiente que não estão visíveis no momento imediato.
- **Agentes Baseados em Metas:** Combinam o estado interno com informações sobre **objetivos desejados** (*goals*), sendo capazes de simular e planejar ações futuras.
- **Agentes Baseados em Utilidade:** Vão além da meta binária ("conseguiu ou não"); calculam uma **função de utilidade** que pondera trade-offs (rapidez vs. custo vs. segurança).
- **Agentes com Aprendizado:** Possuem um componente crítico que avalia as ações e ensina o elemento executor a melhorar o desempenho ao longo do tempo.

O Salto para a IA Agêntica (*Agentic AI*):

Enquanto um chatbot tradicional opera no paradigma **reativo pontual** (você pergunta, ele cospe uma resposta estática e desliga o raciocínio), a **IA Agêntica** possui:

• **Autonomia de Execução:** Recebe uma meta macro ("faça uma auditoria documental da pasta X") e desdobra essa meta em uma cadeia lógica de microações.

• **Uso de Ferramentas (*Tool Use*):** Executa scripts, consulta bancos de dados, consome APIs externas e lê arquivos locais.

• **Ajuste e Correção de Rota:** Monitora o retorno das próprias ações; se uma ferramenta retornar erro, o agente formula uma estratégia alternativa sem interromper o usuário a cada passo.

Por que cai em prova?

A FGV explora essas distinções porque o mercado e os editais de TIC estão inundados de jargões mercadológicos. A banca quer saber se o candidato:

• Distingue um modelo conversacional passivo de um verdadeiro **agente autônomo**.

• Sabe que **todo sistema de IA em produção no planeta Terra é ANI**, e que classificar LLMs comerciais como AGI é erro grosseiro de concurso.

• Conhece a história da ciência da computação para não cair no conto de que a IA "surgiu do nada" nos últimos anos.

Como as partes se conectam?

• **Com T02.2 (Aprendizado de Máquina):** A transição dos sistemas simbólicos dos anos 80 para a IA moderna ocorreu justamente pela adoção massiva do aprendizado estatístico a partir de dados brutos.

• **Com T02.3 (LLMs e Modelos Generativos):** Os grandes modelos de linguagem operam hoje como o "cérebro linguístico" dentro dos sistemas de IA Agêntica, gerando os planos e raciocínios que acionam as ferramentas externas.

• **Com T02.4 (Ética e Governança):** A autonomia da IA Agêntica gera o dilema de ouro da governança: **a responsabilidade ética e jurídica jamais é transferida à máquina**; ela recai sempre sobre os operadores humanos e a instituição.

Pegadinhas clássicas da FGV

■■ PEGADINHA

O Mito do "ChatGPT é AGI":

A banca apresenta o ChatGPT ou outro modelo generativo de ponta e afirma que ele "inaugurou a era da Inteligência Artificial Geral (AGI) devido à sua capacidade universal de resposta".

Classificação técnica: Errado! Por mais impressionante que seja na geração textual, ele é um modelo de **IA Estreita (ANI)**: opera por predição estatística de tokens em linguagem, sem compreensão causal, sem senso comum de mundo e incapaz de operar autonomamente fora do seu escopo computacional.

■■ PEGADINHA

Atribuição de Responsabilidade à IA Agêntica:

Em enunciados sobre agentes autônomos que apoiam pesquisas, perícias ou diagnósticos, a FGV costuma colocar: *"O sistema assume a responsabilidade ética e jurídica pelas conclusões apuradas, dispensando revisão humana"*.

Regra de ouro: A IA é uma ferramenta tecnológica desprovida de personalidade jurídica, capacidade civil ou consciência moral. Toda e qualquer responsabilidade por atos administrativos é **indelegável do agente público humano**.

■■ PEGADINHA

Inversão dos Invernos da IA:

A FGV adora atribuir o primeiro inverno da IA ao colapso das máquinas Lisp ou dos sistemas especialistas.

Linha do tempo rigorosa:

1º Inverno (anos 70): Limitações dos Perceptrons simples e corte militar pós-relatório Lighthill.

2º Inverno (final dos anos 80): Fracasso comercial e rigidez insustentável dos **Sistemas Especialistas**.

■ DICA

O Teste da Ação Reativa × Agêntica:

Se a alternativa descreve uma ferramenta que "depende de comandos pontuais do usuário a cada novo passo", ela descreve **uso reativo tradicional**, e **NÃO comportamento agêntico**. Comportamento agêntico exige: planejamento autônomo, uso coordenado de recursos e ajuste dinâmico para atingir a meta.

O que separa quem acerta de quem erra?

Conceito	Quem Erra	Quem Acerta
	Escala da IA	Acha que AGI já existe ou que carros autônomos são AGI.
	Agência	Acha que um agente inteligente é infalível e garante veracidade factual.
	História	Acredita que as redes neurais foram inventadas após 2010.

Onde eu erraria e por quê?

O maior risco aqui é o **tecnodeslumbramento**. Quando usamos assistentes de IA avançados, tendemos a antropomorfizar a máquina, atribuindo a ela "entendimento", "consciência" ou "autonomia jurídica". Na prova da FGV, mantenha o pé no chão: a IA é uma estrutura algorítmica estatística de processamento de informação.

Como memorizar sem decorar?

- **Níveis de IA:** Escada **ANI** → **AGI** → **ASI** (*Estreita* no presente, *Geral* no horizonte, *Super* na ficção).
- **Tríade do Renascimento Moderno: DGP** — **D**ados massivos (Big Data), **G**PUs (computação paralela) e **P**rofundidade de camadas (Deep Learning).
- **Tripé da IA Agêntica: P**lanejar + **E**xecutar com ferramentas + **A**justar rota (mnemônico **PEA**).

O que revisar e quando?

- **Revisão Relâmpago (30 dias antes):**
  - Definição formal de Dartmouth 1956.
  - Causas dos dois Invernos da IA (Perceptrons nos anos 70; Sistemas Especialistas nos anos 80).
  - Escada de Russell & Norvig (Reativo Simples → Baseado em Modelos → Metas → Utilidade → Aprendizado).
- **Revisão Fina (véspera):**
  - Diferença entre ANI (real) e AGI (teórica).

• O dogma da supervisão humana: a IA nunca responde jurídica ou eticamente por si própria.

Lição para outras matérias

Na prova da Dataprev, essa distinção conceitual dialoga com Governança de TI: assim como na ITIL 4 a tecnologia apoia a criação de valor mas não substitui a governança corporativa, na IA o agente autônomo executa fluxos complexos, mas o controle final do processo sempre pertence ao ser humano (*Human-in-the-loop*).

Atualidades e IA T02.2 — Aprendizado de Máquina (Machine Learning)

> **■■ Visão Geral do Tópico**
>
> Detalha a espinha dorsal da Inteligência Artificial contemporânea: os paradigmas de aprendizado (supervisionado, não-supervisionado e por reforço), as tarefas clássicas de classificação e regressão, a representação de conhecimento em linguagem natural (a virada crucial da Tokenização para os Embeddings Vetoriais Densos) e as armadilhas de validação estatística (*overfitting* e métricas de desempenho).

Do que se trata?

No paradigma clássico da computação, programadores humanos escrevem regras lógicas explícitas (*algoritmos*) que processam dados de entrada para produzir respostas. No **Aprendizado de Máquina (Machine Learning - ML)**, essa lógica inverte-se: nós fornecemos **dados** e **respostas (exemplos)**, e o computador descobre autonomamente as **regras estatísticas** que mapeiam a entrada à saída.

```
flowchart TD
subgraph Paradigma Classico
A1["Regras"] & B1["Dados"] --> C1["Computador"] --> D1["Respostas"]
end
subgraph Machine Learning
A2["Dados"] & B2["Respostas"] --> C2["Computador / Treinamento"] --> D2["Modelo (Regras Matemáticas)"]
end
```

1.1 Os Paradigmas Fundamentais de ML

```
flowchart LR
ML["Machine Learning"] --> Sup["Supervisionado (Dados Rotulados)"]
ML --> Semi["Semi-supervisionado (Híbrido)"]
ML --> NaoSup["Não-Supervisionado (Dados Sem Rótulo)"]
ML --> Ref["Reforço (Tentativa e Erro)"]
```

```
Sup --> Pred["Técnicas Preditivas (Antevem o Futuro)"]
Pred --> Class["1) Classificação (Valores Categóricos)"]
Pred --> Regr["2) Regressão (Valores Numéricos)"]

NaoSup --> Desc["Técnicas Descritivas (Padrões Comuns, Não Preveem)"]
Desc --> Assoc["1) Associação"]
Desc --> Clust["2) Agrupamento / Clusterização"]

Ref --> Agent["Agente em Ambiente Dinâmico (Recompensa/Punição)"]
```

Paradigma	Tipo de Dado de Entrada	Mecânica de Aprendizado e Custo	Aplicações e Técnicas Típicas
	Supervisionado (*Supervised*)	Pares (X, y) rotulados por **supervisor humano**.	O modelo calcula previsões, compara com rótulos reais e ajusta seus pesos. **Mais preciso e mais caro** (custo alto de rotulagem humana).
	Não-Supervisionado (*Unsupervised*)	Dados brutos X, **sem supervisor e não rotulados**.	O algoritmo vasculha a estrutura intrínseca para encontrar características comuns. **Mais barato e menos preciso** (sem controle de rótulo).
	Semi-supervisionado (*Semi-supervised*)	Pequena porção **rotulada** + grande volume **não rotulado**.	Une o melhor dos dois mundos: aproveita dados não rotulados abundantes e baratos, guiados por alguns exemplos rotulados de alto valor.
	Aprendizado por Reforço (*Reinforcement*)	Estados, ações e sinais de **recompensa e punição**.	Baseado estritamente em **tentativa e erro**: um agente autônomo aprende interagindo com o ambiente dinâmico para maximizar recompensas cumulativas.

■ Dica da Banca — Paradigmas e Técnicas de Machine Learning

Supervisionado = Preditivo: Sempre que a questão falar em antever o resultado futuro a partir do passado com dados rotulados por humano, trata-se de aprendizado supervisionado (Classificação para classes/categorias; Regressão para valores numéricos contínuos). É mais preciso, mas o mais caro.

Não-Supervisionado = Descritivo: Busca características comuns e estruturas latentes entre os itens, mas **não faz previsão** de futuro (Agrupamento/Clusterização e Associação). É mais barato e opera sem supervisor.

Semi-supervisionado: Une o melhor dos dois mundos (parte pequena rotulada + massa não rotulada) visando equilibrar custo e precisão.

Reforço: Não usa dados pré-rotulados estáticos; aprende por **tentativa e erro** com recompensas e punições.

1.2 Representação de Conhecimento: Tokenização × Embeddings

Um dos pontos mais cobrados pela FGV na interseção entre Machine Learning e Processamento de Linguagem Natural (PLN) é a forma como o computador "lê" e "entende" texto. Modelos matemáticos não operam sobre palavras; eles operam exclusivamente sobre **números e tensores**.

```
flowchart LR
Texto["Texto Bruto"] -->|Tokenização| Tokens["Tokens (IDs Numéricos Discretos)"]
Tokens -->|Camada de Embedding| Espaco["Espaço Vetorial Denso (Embeddings)"]
Espaco -->|Distância Cosseno| Similaridade["Proximidade Semântica"]
```

A Distinção Vital:

■ **Tokenização (Decomposição Sintática):**

• É o processo mecânico de fatiar um texto em pedaços atômicos chamados *tokens* (que podem ser palavras inteiras, pedaços de palavras ou caracteres individuais — como no algoritmo BPE / *Byte-Pair Encoding*).

• A tokenização apenas associa uma sequência de letras a um número inteiro de catálogo (ex.: `"computador"` $\rightarrow$ ID 4512; `"computação"` $\rightarrow$ ID 9821).

• **Limitação fatal:** Os IDs dos tokens não possuem significado semântico intrínseco. Para o computador, o ID 4512 não tem nenhuma relação de parentesco com o ID 9821; são apenas índices arbitrários de dicionário.

■ **Embeddings Vetoriais Densos (Representação Semântica Contínua):**

• Um **embedding** mapeia cada token ou frase para um **vetor numérico contínuo em um espaço geométrico multidimensional** (geralmente entre centenas e milhares de dimensões, como 768 ou 1536).

• **Propriedade mágica dos embeddings:** Palavras, conceitos ou textos com significados semelhantes são projetados **geometricamente próximos** uns dos outros nesse espaço vetorial (mensurados por métricas como a *similaridade por cosseno*).

• Permitem álgebra semântica: $\vec{v}(\text{"rei"}) - \vec{v}(\text{"homem"}) + \vec{v}(\text{"mulher"}) \approx \vec{v}(\text{"rainha"})$.

• **Por que superam representações esparsas antigas (One-Hot / Bag-of-Words):** Em vez de matrizes gigantescas com 100.000 colunas repletas de zeros (esparsas), os embeddings concentram informação rica em vetores de tamanho fixo compactos (densos), capturando sinônimos, contexto e analogias.

1.3 Conceitos Críticos de Treinamento e Avaliação

• **Overfitting (Superajuste):** O modelo "decora" os ruídos e particularidades do conjunto de treinamento. Ele tem desempenho perfeito no treino, mas erra grosseiramente diante de dados novos e inéditos (baixa capacidade de generalização).

• **Underfitting (Subajuste):** O modelo é simples demais para capturar os padrões subjacentes aos dados (erra tanto no treino quanto no teste).

• **A Matriz de Confusão e suas Métricas:**

• **Acurácia:** Proporção geral de acertos. É perigosa e enganosa em conjuntos de dados desbalanceados (ex.: se 99% das transações são legítimas e 1% são fraudes, um modelo idiota que disser "tudo é legítimo" terá 99% de acurácia, mas detectará zero fraudes!).

• **Precisão (*Precision*):** *"De todos os casos que o modelo classificou como positivos, quantos eram realmente positivos?"* Priorizada quando o custo do falso positivo é alto.

• **Revocação / Sensibilidade (*Recall*):** *"De todos os casos que eram de fato positivos no mundo real, quantos o modelo conseguiu capturar?"* Priorizada em diagnósticos de doenças graves e detecção de ataques de segurança cibernética (onde deixar passar um caso positivo é fatal).

• **F1-Score:** Média harmônica entre Precisão e Recall, ideal para avaliar modelos em cenários desbalanceados.

Por que cai em prova?

A FGV formula questões práticas e conceituais de ML para:

• Derrubar candidatos que confundem a etapa mecânica da **Tokenização** com a representação conceitual dos **Embeddings**.

• Avaliar se o futuro analista de TIC sabe escolher o paradigma correto para um problema de negócio da administração pública (ex.: agrupamento de cidadãos sem rótulo prévio é não-supervisionado; prever inadimplência com base em histórico é supervisionado).

• Exigir discernimento técnico sobre as métricas de validação de modelos.

Como as partes se conectam?

• **Com T02.1 (Conceitos de IA):** O aprendizado de máquina é a subárea da IA que permitiu a superação dos sistemas especialistas baseados em regras manuais.

• **Com T02.3 (Modelos Generativos e LLMs):** Os LLMs utilizam embeddings como camada de entrada (*input embeddings*) e saída, e empregam o mecanismo de *Atenção* justamente para calcular a relação contextual entre esses vetores.

• **Com Banco de Dados e Big Data:** Bancos de dados vetoriais modernos (*Vector Databases*, como Pinecone, Milvus, pgvector no PostgreSQL) foram criados especificamente para indexar e realizar buscas por similaridade sobre esses embeddings.

Pegadinhas clássicas da FGV

■■ PEGADINHA

Confundir Tokenização com Embedding:

A banca afirma que "a tokenização é responsável por calcular o significado semântico e a proximidade conceitual entre termos em um espaço vetorial contínuo".

Distinção obrigatória: A tokenização apenas fatia o texto em pedaços e atribui códigos inteiros (IDs). Quem confere **significado semântico e geometria contínua é o EMBEDDING**!

■■ PEGADINHA

Supervisionado × Não-Supervisionado em Agrupamento:

A FGV apresenta um caso em que uma organização quer descobrir grupos homogêneos de usuários em sua base cadastral, sem qualquer categorização prévia, e diz que se deve usar "regressão linear supervisionada".

Correção: Descobrir grupos sem rótulos prévios é a tarefa clássica de **Clustering (Agrupamento)**, pertencente ao aprendizado **NÃO-SUPERVISIONADO**.

■ **ALERTA**

A ilusão da Acurácia em Dados Desbalanceados:

Se a questão descrever um cenário de auditoria em que as fraudes representam 0,1% das licitações, jamais confie na acurácia como métrica definitiva de sucesso. A métrica correta para avaliar a detecção efetiva dos fraudadores é o **Recall (Sensibilidade)** e o **F1-Score**.

■ **DICA**

Palavras-chave dos Paradigmas:

Rótulo, gabarito, histórico classificado, predição de valor contínuo $\rightarrow$ **Supervisionado**.

Padrão oculto, agrupamento, sem rótulo, segmentação $\rightarrow$ **Não-Supervisionado**.

Recompensa, punição, agente, ambiente dinâmico, tentativa e erro $\rightarrow$ **Por Reforço**.

O que separa quem acerta de quem erra?

Questão-Chave	Quem Erra	Quem Acerta
	Representação Semântica	Acha que o computador compara letras ou que tokens possuem significado.
	Classificação vs. Regressão	Confunde variável discreta/categórica com variável contínua/numérica.
	Overfitting	Acha que 100% de acerto no treino é o objetivo final de qualquer modelo.

Onde eu erraria e por quê?

O maior ponto de tropeço é tentar resolver questões de PLN achando que "embedding" é apenas uma lista de palavras. Lembre-se: embedding é uma **representação matemática densa**, onde a proximidade geométrica reflete proximidade semântica. Se o enunciado falar em "vetores contínuos" ou "espaço latente", procure imediatamente *embeddings*.

Como memorizar sem decorar?

- **Paradigmas: S**upervisionado tem **S**upervisor (professor dando a resposta certa); **N**ão-supervisionado é **N**avegar sozinho; por **R**eforço é **R**ecompensa (adestramento com petisco).
- **Token vs. Embedding:** *"Token corta a pizza em fatias; Embedding diz o sabor de cada pedaço."*
- **Classificação vs. Regressão:** *"Classificação escolhe a gaveta; Regressão mede na régua."*

O que revisar e quando?

- **Revisão Relâmpago (30 dias antes):**
  - Diferença entre Classificação, Regressão, Clustering e RL.
  - O papel dos Embeddings vs. Tokenização.
  - Conceito de Overfitting e métodos para evitá-lo (regularização, validação cruzada).
- **Revisão Fina (véspera):**
  - Fórmulas intuitivas de Precisão vs. Recall.
  - Áreas de aplicação de RLHF em modelos de linguagem.

Lição para outras matérias

Em Banco de Dados (Módulo II), quando estudamos *Modelagem Dimensional* e *Data Lakes*, a ingestão de dados não estruturados (textos, imagens) depende diretamente desses vetores de embedding para viabilizar consultas semânticas em bases modernas de Big Data.

Atualidades e IA T02.3 — Modelos Generativos e Modelos de Linguagem (LLMs)

■■ Visão Geral do Tópico

Explora a fronteira mais dinâmica da tecnologia: a arquitetura e taxonomia dos Modelos Generativos (GANs, Difusão e Transformers), o funcionamento interno dos Modelos de Linguagem de Grande Porte (LLMs), os pilares da engenharia de prompts, as estratégias de mitigação de alucinações (com destaque para RAG e Fine-Tuning) e o paradigma sociotécnico da complementariedade no mercado de trabalho.

Do que se trata?

Historicamente, a maior parte dos algoritmos de aprendizado de máquina era **discriminativa**: recebia dados e aprendia a traçar uma fronteira de decisão ($P(Y|X)$) para classificar se um e-mail era spam ou não, ou se um tumor era maligno. A **Inteligência Artificial Generativa (IAG)** opera em um nível muito mais complexo: ela aprende a distribuição de probabilidade subjacente aos dados ($P(X)$) para **criar novos artefatos inéditos** (textos, imagens, códigos, áudios e vídeos) que se assemelham perfeitamente aos exemplos do treinamento.

```
flowchart TD
A["Famílias de Modelos Generativos"] --> B["GANs (Redes Adversárias)"]
A --> C["Modelos de Difusão (Diffusion)"]
A --> D["Transformers Autorregressivos (LLMs)"]

B --> B1["Gerador vs Discriminador (Jogo de Soma Zero)"]
C --> C1["Adição de Ruído + Desruidificação Progressiva"]
D --> D1["Mecanismo de Atenção (Vaswani et al., 2017)"]
```

1.1 As Principais Arquiteturas Generativas

■ **GANs (*Generative Adversarial Networks*):**

- Propostas por Ian Goodfellow em 2014, baseiam-se na disputa entre duas redes neurais:
  - O **Gerador:** Tenta fabricar dados falsos (imagens realistas de rostos humanos, por exemplo).
  - O **Discriminador:** Atua como um perito policial que tenta adivinhar se a imagem é real (da base original) ou falsa (feita pelo gerador).
- O treinamento é um jogo teórico minimax de soma zero: conforme o discriminador fica mais rigoroso, o gerador torna-se mais sofisticado, até que as amostras fabricadas tornam-se indistinguíveis das reais.

■ **Modelos de Difusão (*Diffusion Models*):**

- Base de ferramentas modernas de geração de imagem como Midjourney, Stable Diffusion e DALL-E 3.
- Operam em dois passos: no processo *direto*, adicionam ruído gaussiano progressivo a uma imagem até ela virar puro ruído estático; no processo *inverso*, a rede aprende a remover o ruído passo a passo, reconstruindo uma imagem límpida condicionada a um prompt textual.

■ **Transformers (A Revolução do Processamento de Linguagem):**

- Introduzidos no artigo seminal do Google *"Attention Is All You Need"* (Vaswani et al., 2017).
- Substituíram as antigas redes recorrentes (RNNs e LSTMs), que processavam palavras uma por uma em sequência linear (o que gerava esquecimento de contextos longos e impedia paralelização em larga escala).
- O Transformer processa **todos os tokens de entrada simultaneamente (em paralelo)** por meio do mecanismo de **Autoatenção (*Self-Attention*)**.

1.2 Como Funciona um Grande Modelo de Linguagem (LLM)?

Modelos como a família GPT, Claude, Gemini e LLaMA são **modelos de linguagem autorregressivos baseados no decodificador do Transformer**.

```
flowchart LR
Contexto["Contexto Precedente (Prompt)"] --> LLM["LLM (Transformer Decodificador)"]
LLM --> Distr["Distribuição de Probabilidade"]
Distr --> Token["Amostragem do Próximo Token"]
Token --> Loop["Realimenta o Contexto"]
```

- **Mecânica Central (Predição do Próximo Token):** Um LLM não "pensa", não "raciocina" como um ser humano e não consulta uma enciclopédia interna estática. Ele é um mecanismo probabilístico massivo calibrado para calcular: *"Dada esta sequência de palavras que acabou de passar, qual é estatisticamente o próximo token mais provável de aparecer?"*.
- **O Funil de Treinamento em Três Fases:**
  - **Pré-treinamento (*Pre-training*):** O modelo consome terabytes de texto da internet de forma não supervisionada para aprender a estrutura gramatical, fatos gerais e padrões de linguagem (gera o modelo base).
  - **Ajuste Fino Supervisionado (*SFT - Supervised Fine-Tuning*):** O modelo é treinado com pares selecionados de perguntas e respostas de alta qualidade elaboradas por especialistas humanos, aprendendo a agir como um assistente prestativo.
  - **Alinhamento com Feedback Humano (*RLHF*):** Aplicam-se técnicas de Aprendizado por Reforço para punir respostas tóxicas, enganosas ou perigosas e premiar respostas seguras, concisas e úteis.

1.3 Técnicas Avançadas: Engenharia de Prompts, RAG e Fine-Tuning

Técnica	Como Funciona	Quando Utilizar	Vantagens e Trade-offs
	Engenharia de Prompts (*Prompt Engineering*)	Instrução formulada na entrada sem alterar nenhum parâmetro do modelo (*Zero-shot*, *Few-shot* com exemplos, *Chain-of-Thought* para raciocínio passo a passo).	Ajustes rápidos, tarefas padrão e triagens pontuais.
	RAG (*Retrieval-Augmented Generation*)	Antes de gerar a resposta, o sistema busca trechos relevantes em um banco de dados vetorial de documentos privados da organização e injeta esses trechos no prompt do LLM.	**Consultas a bases corporativas da Dataprev**, manuais internos, normas legais atualizadas e auditorias.
	Ajuste Fino (*Fine-Tuning* / LoRA)	Retreina frações dos pesos matemáticos do modelo para especializá-lo em um formato específico ou jargão técnico restrito.	Tarefas de estilo muito rígido, conformidade estrita de saída (JSON específico) ou linguagens de domínio próprio.

1.4 A Alucinação (*Hallucination*) e Limitações Estruturais

A **alucinação** é a tendência inerente dos LLMs de gerar com absoluta firmeza sintática e convicção factual afirmações que são **completamente falsas, inventadas ou inexistentes** (como inventar decisões judiciais, números de leis ou artigos científicos).

> ■ **ALERTA**
>
> **Por que os LLMs alucinam?**
>
> A alucinação não é um "bug" que será consertado amanhã com um simples patch; ela decorre da própria **natureza estocástica/probabilística da arquitetura**. O modelo otimiza para que o texto pareça plausível, coerente e gramaticalmente perfeito, e não para garantir a correspondência com a verdade do mundo real.

1.5 O Paradigma da Complementariedade (IA como Copiloto no Trabalho)

Nas questões interdisciplinares da FGV envolvendo sociologia do trabalho, serviço social e novas tecnologias, a banca cobra a postura crítica sobre o impacto da IA no emprego.

> ■■ **PEGADINHA**
>
> **O Mito da "Substituição Integral":**
>
> A FGV coloca alternativas afirmando que a IA generativa "tornará obsoleta e substituirá integralmente a força de trabalho intelectual humana (jornalistas, advogados, analistas e gestores)".
>
> **O Paradigma Oficial da Banca:**

As bancas de concurso adotam firmemente a **Regra da Complementariedade**: a tecnologia atua como **ferramenta de apoio, eficiência operacional e copiloto nos bastidores**. A mediação crítica, o julgamento interpretativo, a validação de fontes e a responsabilidade ética permanecem indelegáveis das pessoas.

Por que cai em prova?

A FGV exige que o servidor público compreenda:

- A mecânica do **Transformer e da Autoatenção** para não tratar a IA como "mágica".
- A utilidade do **RAG** na administração pública: a Dataprev não vai treinar um modelo do zero toda semana; ela conecta um LLM de mercado às bases sociais do governo via RAG.
- Os riscos de segurança da informação: vazamento de dados pessoais em prompts de ferramentas públicas e as consequências jurídicas das alucinações.

Como as partes se conectam?

- **Com T02.2 (Aprendizado de Máquina):** O mecanismo de autoatenção calcula o relacionamento entre os *embeddings vetoriais densos* de cada palavra.
- **Com T02.4 (Ética e Governança):** As alucinações dos LLMs tornam obrigatória a exigência do *Human-in-the-loop* (nenhuma decisão administrativa que afete direitos de cidadãos pode ser tomada sem validação humana).
- **Com Legislação (LGPD):** Submeter dados cadastrais de cidadãos brasileiros a provedores estrangeiros de LLMs sem salvaguardas viola as regras de transferência internacional de dados e o princípio da segurança.

Pegadinhas clássicas da FGV

■■ PEGADINHA

RAG × Fine-Tuning para Mitigar Alucinação:

A banca sugere que para uma empresa estatal evitar alucinações e consultar manuais internos atualizados diariamente, a melhor estratégia é fazer "Fine-Tuning contínuo de todos os parâmetros do modelo".

Correção técnica: O Fine-Tuning altera o comportamento e o estilo do modelo, mas **não é eficiente para memorizar fatos dinâmicos e continua sujeito a alucinações**. A arquitetura correta e consagrada pelo mercado para incorporar documentos corporativos atualizados e eliminar alucinações é o **RAG (Retrieval-Augmented Generation)**.

■■ PEGADINHA

Veracidade Ontológica × Coerência Estatística:

Alternativas que afirmam que "modelos com bilhões de parâmetros garantem a veracidade das fontes e a eliminação de contradições lógicas em textos históricos" estão erradas! Nenhum tamanho de parâmetro elimina o caráter estocástico da amostragem de tokens.

■ **DICA**

Vocabulário Radical em Questões de IA e Sociedade:

Elimine sem hesitar qualquer alternativa que use termos absolutos e excludentes: *"substituir integralmente"*, *"dispensa mediação humana"*, *"imune a falhas"*, *"elimina completamente qualquer desafio ético"*. As respostas corretas adotam tom sóbrio: *apoio*, *complementariedade*, *ferramenta auxiliar*, *mitigação de riscos*.

O que separa quem acerta de quem erra?

Conceito	Quem Erra	Quem Acerta
	Como o LLM gera texto	Acha que o modelo "pesquisa no Google" internamente a cada palavra.
	Alucinação	Atribui a alucinação à falta de dados ou falha de programação.
	RAG	Acha que RAG serve para retreinar a rede neural.

Onde eu erraria e por quê?

O maior risco é supor que, por escrever um português impecável, o LLM "sabe o que está dizendo". A perfeição sintática disfarça erros conceituais grotescos. Na prova, lembre-se: alta fluência verbal **não é sinônimo** de precisão factual.

Como memorizar sem decorar?

- **Transformer:** *"Attention Is All You Need"* $\rightarrow$ Atenção paralela em vez de leitura em fila (RNN).
- **RAG: R**ecupera o documento no banco $\rightarrow$ **A**umenta o prompt com o texto $\rightarrow$ **G**era a resposta embasada.
- **Papel da IA no Trabalho:** Regra do **Copiloto** (o humano é o piloto comandante; a IA é o copiloto nos bastidores).

O que revisar e quando?

- **Revisão Relâmpago (30 dias antes):**
  - Diferença entre GANs (gerador vs discriminador), Modelos de Difusão (ruído) e Transformers.
  - As 3 fases do treino de LLMs: Pré-treino $\rightarrow$ SFT $\rightarrow$ RLHF.
  - Arquitetura e componentes do RAG.
- **Revisão Fina (véspera):**
  - Causa fundamental das alucinações (amostragem probabilística).
  - Regra da complementariedade nas relações de trabalho.

Lição para outras matérias

Em arquiteturas corporativas, o conceito de RAG conecta-se diretamente com a infraestrutura de TI: envolve servidores de busca vetorial, armazenamento S3 para arquivos fonte e APIs seguras de mensageria, integrando inteligência artificial à arquitetura tradicional de sistemas corporativos.

Atualidades e IA T02.4 — Ética, Governança e Privacidade em IA

> **■■ Visão Geral do Tópico**
>
> Concentra os aspectos jurídicos, éticos e de governança corporativa da Inteligência Artificial: o combate ao viés algorítmico, os requisitos de Explicabilidade (XAI) e transparência decisória, o dogma da supervisão humana (*Human-in-the-loop*), a responsabilidade indelegável do servidor público, os tratados internacionais (Convenção de Vilnius e o modelo europeu baseado em risco), a aplicação territorial da LGPD (*web scraping* de dados públicos) e a integração com os frameworks COBIT 2019 e ITIL 4.

Do que se trata?

A Inteligência Artificial deixou de ser um mero experimento técnico de laboratório para se tornar um **instrumento de poder decisório do Estado e das corporações**. Quando algoritmos decidem quem recebe um benefício previdenciário, quem obtém crédito ou quem tem o currículo descartado, surgem questões urgentes de justiça distributiva, devido processo legal e proteção da dignidade humana.

```
flowchart TD
A["Pilares da Governança de IA"] --> B["Ética & Justiça Algorítmica"]
A --> C["Transparência & Explicabilidade (XAI)"]
A --> D["Supervisão Humana (HITL)"]
A --> E["Regulação & Direito Digital"]
A --> F["Governança de TIC (COBIT / ITIL)"]

B --> B1["Mitigação de Viés (Bias & Fairness)"]
C --> C1["Superação da 'Caixa-Preta' (Black Box)"]
D --> D1["Responsabilidade Indelegável do Agente"]
E --> E1["Convenção de Vilnius (CETS 225)"]
E --> E2["LGPD: Extraterritorialidade & Web Scraping"]
F --> F1["Criação de Valor & Gestão de Riscos"]
```

1.1 O Mito do Algoritmo Neutro e o Viés Algorítmico (*Algorithmic Bias*)

Um dos erros mais perigosos combatidos pela literatura moderna e pelas bancas de concurso é a crença de que *"a matemática é pura, logo os computadores são imunes a preconceitos"*.

■ **ALERTA**

Como nasce o viés na Inteligência Artificial?

Os algoritmos aprendem padrões estatísticos a partir de **dados históricos gerados por sociedades humanas desiguais**. Se os dados históricos refletem assimetrias raciais, de gênero, de renda ou de acesso à justiça, o modelo não apenas reproduz essas distorções, mas as **amplifica e legitima com uma capa enganosa de objetividade científica** (*Garbage in, garbage out*).

• **Discriminação Algorítmica Indireta (*Proxies*):** Mesmo que você remova variáveis sensíveis diretas (como raça ou religião) do banco de dados, o algoritmo aprende a utilizar variáveis correlacionadas (*proxies* — como CEP de residência, escola de formação ou histórico de crédito do bairro) para perpetuar a discriminação sem usar explicitamente a palavra proibida.

• **O Axioma "Bias In, Bias Out":** Se os dados de entrada espelham assimetrias históricas, o modelo matematicamente reproduzirá decisões enviesadas. A ausência de dolo ou intenção explícita do desenvolvedor **não elide** a ilicitude do resultado discriminatório.

• **Auditoria de Justiça (*Fairness*):** Exige testes contínuos de paridade estatística e equidade de impacto em subgrupos vulneráveis antes e após a implantação de qualquer modelo no serviço público.

1.2 Explicabilidade e Transparência: A Inteligência Artificial Explicável (XAI)

Em sistemas complexos de *Deep Learning*, o processamento ocorre através de centenas de camadas ocultas e bilhões de parâmetros matemáticos ponderados simultaneamente. Esse fenômeno é conhecido como o **Problema da Caixa-Preta (*Black-Box Problem*)**: nem mesmo os próprios engenheiros que projetaram o código conseguem explicar com clareza o caminho determinístico que levou a uma decisão específica.

```
flowchart LR
Entrada["Dados do Cidadão"] --> Modelo["Modelo Complexo (Caixa-Preta)"]
Modelo --> Decisao["Decisão: Benefício Negado"]
Decisao --> XAI["Camada XAI (SHAP / LIME)"]
XAI --> Relatorio["Explicabilidade: 'Fatores Determinantes A, B e C'"]
```

O Espectro de Interpretabilidade dos Modelos

Categoria	Interpretabilidade	Exemplos de Modelos	Características em Prova
	Modelos Transparentes (*White Box*)	**Alta** (Intrínseca)	Regressão Linear, Regressão Logística, Árvores de Decisão, Sistemas Especialistas Baseados em Regras.
	Modelos Opacos (*Black Box*)	**Baixa** (Opacidade Algorítmica)	Redes Neurais Profundas (*Deep Learning*), Redes Convolucionais (CNNs), *Ensembles* densos (Random Forests, XGBoost).

Requisitos de Governança e Direito:

• **Diferença entre Transparência do Código e Explicabilidade da Decisão:** Publicar o código-fonte de uma rede neural profunda de bilhões de parâmetros não resolve nada para o cidadão comum nem para o auditor fiscal. A **Explicabilidade (XAI)** exige fornecer uma explicação compreensível em linguagem natural

sobre **quais atributos pesaram mais e por que o resultado foi produzido**.

• **O Direito à Revisão e Explicação (Art. 20 da LGPD):** O titular dos dados tem o direito de solicitar a revisão de decisões tomadas unicamente com base em tratamento automatizado que afetem seus interesses, bem como de receber informações claras e adequadas sobre os critérios e procedimentos utilizados.

■ Suposição vs. Demonstração Factual

A explicabilidade não existe para permitir "suposições", "especulações" ou "deduções aproximadas" por parte das partes envolvidas. Seu papel legal e técnico é permitir a **reconstituição factual, lógica e auditável** do nexo decisório.

1.3 Supervisão Humana e o Papel do Servidor Público (*Human-in-the-Loop*)

No setor público, a autonomia irrestrita de algoritmos choca-se frontalmente com o princípio constitucional da legalidade, da motivação dos atos administrativos e com o Código de Ética Profissional do Servidor Público (**Decreto nº 1.171/1994**).

Nível de Supervisão	Como Opera na Prática	Aplicação no Setor Público
	Human-in-the-loop (HITL)	O sistema de IA gera minutas, triagens e recomendações, mas **a decisão final exige validação, assinatura e juízo crítico obrigatório do servidor humano**.
	Human-on-the-loop (HOTL)	O sistema opera autonomamente em tempo real, mas com um operador humano monitorando continuamente os painéis e detendo o poder de interromper (*kill switch*) ou reverter a operação a qualquer momento (*override*).
	Human-out-of-the-loop	Operação 100% automatizada de ponta a ponta sem supervisão humana.

■■ O Trio Semântico da FGV na Supervisão Humana

Fique em alerta máximo contra alternativas que empreguem:

"Prescindindo" de avaliação humana (*prescindir* = dispensar/não precisar);

"Dispensando" conferência ou validação prévia de peritos;

"Devendo prevalecer" o prognóstico do algoritmo sobre o juízo do especialista humano.

Em infraestruturas críticas e atos de Estado, a IA atua estritamente como **Sistema de Apoio à Decisão**. A autoridade humana detém poder de veto (*override*) irrevogável.

■■ PEGADINHA

A Responsabilidade Indelegável do Servidor Público:

Em hipótese alguma o servidor público pode justificar um erro, uma negligência ou um ato discriminatório alegando que *"apenas seguiu a recomendação da ferramenta de IA"*. O servidor é civil, penal e administrativamente responsável pela decisão assinada. A IA é mero instrumento de suporte operacional.

1.4 Regulação Global e Marcos Jurídicos Internacionais

■ **A Convenção de Vilnius (CETS nº 225 - Conselho da Europa, 2024):**

• É o **primeiro tratado internacional juridicamente vinculativo sobre Inteligência Artificial, Direitos Humanos, Democracia e Estado de Direito**.

• Aberto para assinatura em 5 de setembro de 2024 em Vilnius (Lituânia), durante a Conferência dos Ministros da Justiça do Conselho da Europa.

• Assinado por democracias globais de ponta: Estados Unidos, Reino Unido, União Europeia, Israel, Noruega, Islândia, Geórgia, Andorra e Moldávia.

• **Pegadinha de prova:** A convenção foi negociada no âmbito do *Comitê de Inteligência Artificial (CAI)* do Conselho da Europa, e **NÃO decorre exclusivamente do G20**.

■ **A Abordagem Baseada em Risco (*Risk-Based Approach* — Modelo Europeu / AI Act):**

• **Risco Inaceitável (Proibido):** Sistemas de pontuação social por parte de governos (*social scoring*), manipulação comportamental subliminar e identificação biométrica facial remota em massa em tempo real em espaços públicos (salvo exceções gravíssimas de segurança).

• **Alto Risco (Severamente Regulado):** Sistemas usados em infraestruturas críticas, recrutamento de trabalhadores, concessão de crédito, sistemas judiciais, saúde e serviços públicos essenciais. Exigem avaliação prévia de impacto, governança estrita de dados de treino, documentação técnica exaustiva e supervisão humana obrigatória.

• **Risco Específico de Transparência:** Chatbots (obrigação expressa de avisar ao usuário que ele está interagindo com uma IA) e conteúdos sintéticos (*deepfakes* / obrigação de rotulagem e marca d'água digital).

• **Risco Mínimo ou Nulo:** Jogos de videogame e filtros de spam (sem restrições regulatórias pesadas).

1.5 A LGPD Aplicada à IA: Web Scraping e Extraterritorialidade

A Lei Geral de Proteção de Dados Pessoais (**Lei nº 13.709/2018**) impõe limites estritos aos métodos de coleta e treino de modelos de IA no Brasil.

```
flowchart TD
A["Dados Disponíveis na Internet (Públicos)"] --> B["Continua sendo Dado Pessoal? SIM!"]
B --> C["A LGPD se aplica? SIM!"]
C --> D["Exigência: Finalidade Legítima + Boa-fé + Segurança"]

E["Empresa de IA sediada no exterior"] --> F["Serviço ofertado a cidadãos no Brasil?"]
F -->|SIM| G["Art. 3º LGPD: Aplicação Extraterritorial Obrigatória"]
```

• **O Mito do "Dado Público":** O fato de um dado ter sido publicado na internet pelo próprio titular (em redes sociais, blogs ou portais de transparência) **NÃO transforma o dado em propriedade pública de livre apropriação**. O treinamento de modelos de IA por raspagem em massa (*web scraping*) continua sendo uma operação de **tratamento de dados pessoais**, exigindo base legal adequada, finalidade legítima, respeito à legítima expectativa do titular e salvaguardas de segurança (Art. 7º, § 4º da LGPD).

• **O Princípio da Extraterritorialidade (Art. 3º da LGPD):** Não importa que a empresa de IA tenha sua sede no Vale do Silício ou na Irlanda, e que seus servidores em nuvem estejam fisicamente na Virgínia: **se o serviço for ofertado a pessoas no Brasil ou se os dados tiverem sido coletados em território nacional, a lei brasileira aplica-se integralmente**.

1.6 Conexão com Frameworks de Governança de TI: COBIT 2019 e ITIL 4

Em concursos de TIC, a governança de IA é cobrada em harmonia com as melhores práticas de governança corporativa:

- **COBIT 2019 e a Criação de Valor com IA:**
  - O Princípio nº 1 do Sistema de Governança do COBIT 2019 é **"Prover Valor para as Partes Interessadas"** (*Provide Stakeholder Value*).
  - A criação de valor exige o equilíbrio dinâmico entre três pilares: **Realização de Benefícios**, **Otimização de Riscos** e **Otimização de Recursos**.
  - A governança de IA não pode ser um silo isolado do time de cientistas de dados; ela deve ser integrada à arquitetura holística de ponta a ponta da corporação.
- **ITIL 4 e a Gestão de Serviços Inteligentes:**
  - A prática de **Validação e Testes de Serviço** (*Service Validation and Testing*) assegura que novos modelos de aprendizado de máquina passem por testes rigorosos de integridade, viés e segurança cibernética antes da transição para o ambiente de produção.
  - A **Central de Serviços (*Service Desk*)** integra agentes de IA para triagem inteligente e autoatendimento, respeitando o princípio orientador de *"Otimizar e Automatizar"*, mas mantendo canais fluidos de escalada para o suporte humano para lidar com exceções e incidentes complexos.

Por que cai em prova?

A Administração Pública lida com as bases de dados mais sensíveis da República Federativa do Brasil. A Gestão de Serviços de TIC exige profissionais que:

- Saibam que inovação tecnológica sem conformidade jurídica gera multas astronômicas da ANPD e danos irreparáveis à imagem institucional.
- Entendam a mecânica dos tratados internacionais e a regulação baseada em risco.
- Saibam articular os modelos de Machine Learning dentro da arquitetura de governança do COBIT 2019 e ITIL 4.

Como as partes se conectam?

- **Com Legislação (Módulo I):** A LGPD e a Lei de Acesso à Informação (LAI) dialogam diretamente com a exigência de explicabilidade e privacidade nos algoritmos de Estado.
- **Com Gestão e Governança de TI (Módulo II):** O COBIT 2019 e o ITIL 4 fornecem a estrutura de processos, papéis e responsabilidades para que a IA opere com segurança e alinhamento estratégico.

Pegadinhas clássicas da FGV

■■ PEGADINHA

A Ilusão do "Dado Acessível Publicamente":

A banca afirma que "como as informações foram obtidas por web scraping de páginas abertas da internet, o desenvolvedor de IA fica dispensado de observar os princípios e direitos previstos na LGPD".

Regra de ouro: Dado pessoal publicamente acessível **continua sendo dado pessoal protegido pela LGPD**! A dispensa de consentimento não dispensa a observância da finalidade, da boa-fé e dos demais princípios da lei.

■■ PEGADINHA

A Extraterritorialidade e a Sede no Exterior:

A empresa alega que não precisa responder à ANPD ou à Justiça brasileira porque está sediada nos EUA e seus servidores ficam fora do Brasil.

Artigo 3º da LGPD: Se os dados foram coletados no Brasil ou se os serviços de IA são oferecidos a indivíduos localizados em território nacional, a LGPD aplica-se imperativamente.

■■ PEGADINHA

A Origem da Convenção de Vilnius sobre IA:

A FGV adora atribuir a Convenção de Vilnius (2024) ao G20 ou à OCDE.

Precisão factual: Foi elaborada no âmbito do **Conselho da Europa** (*Council of Europe*), sendo aberta para assinatura em Vilnius (Lituânia) na Conferência dos Ministros da Justiça.

■ DICA

Explicabilidade vs. Simples Fornecimento de Código:

Em questões sobre XAI (IA Explicável) e auditoria algorítmica, atente para o seguinte: fornecer o código-fonte ou listar a arquitetura da rede não cumpre o requisito de transparência do processo decisório. A explicabilidade exige detalhar os **fatores determinantes ponderados e como a conclusão foi alcançada**.

O que separa quem acerta de quem erra?

Tema	Quem Erra	Quem Acerta
	Viés	Acredita que algoritmos matemáticos são neutros por definição.
	Supervisão Humana	Aceita alternativas em que a IA decide atos públicos de forma 100% autônoma.
	Governança COBIT	Vê a IA como um projeto isolado de TI.

Onde eu erraria e por quê?

O maior risco é a tentação de acreditar que exigências éticas e jurídicas "atrasam a inovação". Na visão dos tribunais de contas (TCU) e da FGV, **a conformidade com a legalidade e a proteção aos direitos fundamentais é requisito prévio inegociável** para qualquer investimento público em tecnologia da informação.

Como memorizar sem decorar?

- **Graus de Risco Europeus (AI Act):** Pirâmide de 4 andares: **Inaceitável** (Proibido) $\rightarrow$ **Alto** (Supercontrolado) $\rightarrow$ **Específico** (Avisa que é robô) $\rightarrow$ **Mínimo** (Livre).
- **HITL vs HOTL:** *In-the-loop* o humano decide na caneta; *On-the-loop* o humano vigia no painel com o botão de emergência na mão.
- **LGPD em Nuvem:** *"Onde o cidadão brasileiro está, a lei da proteção vai atrás."* (Extraterritorialidade).

O que revisar e quando?

- **Revisão Relâmpago (30 dias antes):**
  - Convenção de Vilnius (CETS 225): primeiro tratado internacional vinculativo, Conselho da Europa, 2024.
  - Artigos 3º (extraterritorialidade) e 20 (decisão automatizada) da LGPD.
  - Os 4 níveis de risco do AI Act.
- **Revisão Fina (véspera):**
  - O dogma da responsabilidade pessoal do servidor público (HITL).
  - Princípio 1 do COBIT 2019 aplicado a projetos de IA.

Lição para outras matérias

A governança algorítmica é a síntese perfeita da área de TIC: ela amarra a tecnologia (redes e servidores), a análise de dados (bancos relacionais e Big Data), as práticas corporativas (ITIL e COBIT) e a legalidade democrática (LGPD e Constituição).

■ **Última atualização:** 10/11/2026